

班 级：油气井工程 2018 级
学 号：2018312032



中国石油大学
CHINA UNIVERSITY OF PETROLEUM

最优化方法课程作业

题 目	优化方法中的两步迭代
学院名称	石油工程学院
专业名称	油气井工程
姓 名	孟庆鑫
任课教师	刘建军

优化方法中的两步迭代

孟庆鑫

摘要: 这不是一篇论文, 因此文章相对轻松. 本文旨在阐述我对一类优化方法中共同的两步迭代思想的理解: 两步迭代是一种反馈策略, 正向过程逼近解, 反馈过程调整逼近方向, 迭代不动点即为最优解. 前半部分是对算法的理解, 不涉及算法细节, 后半部分是应用举例, 附件包含部分举例代码.

1 从梯度下降开始

对于求 $\arg \min_{\theta \in \mathbb{R}^n} J(\theta)$, 梯度下降的核心是如下迭代:

$$\hat{\theta} \leftarrow \hat{\theta} - \alpha \frac{\partial}{\partial \theta} J(\hat{\theta}),$$

这可以看作是两个过程: 修改 $\hat{\theta}$ 使得 $J(\theta)$ 下降; 确定如何修改 (即负梯度).

梯度下降是一个大家族, 有几个变体: 批量梯度下降 (*Batch Gradient Descent*)、随机梯度下降 (*Stochastic Gradient Descent*, 这两个都是针对样本的)、牛顿法 (当 α 取 *Hessian* 矩阵的逆)、共轭梯度 (最优步长梯度下降前后两次方向正交, 而共轭梯度前后两次方向共轭正交, 可以看作是在 *Hilbert* 空间上的另一种内积定义).

神经网络的反向传播也是通过梯度下降完成的. 正向过程通过嵌套输出估计, 反馈过程通过梯度下降减少估计误差.

梯度, 本质上是待优化目标 $J(\theta)$ 的结构特征, 是一种局部信息, 是在局部尺度上以贪心策略最速下降, 但当 $J(\theta)$ 结构无法获取的时候, 梯度也就无法获取 (即信息缺失), 这时只需近似找到使得 $J(\theta)$ 下降的方向即可.

2 PSO, k -means, ICP

这三个算法都不是通过梯度构建的, 但都是两步迭代的优化方法.

2.1 PSO

PSO 没有使用梯度信息, 转而使用一群点来弥补信息缺失: 对一组解 x_i 及其对应的优化方向 v_i , $\forall i$ 迭代执行

$$\begin{aligned} v_i &\leftarrow \omega \cdot v_i + c_1 \cdot \text{rand} \cdot (p_i - x_i) + c_2 \cdot \text{rand} \cdot (g_i - x_i), && \text{确定如何修改,} \\ x_i &\leftarrow x_i + v_i, && \text{修改 } x_i, \end{aligned}$$

直到收敛. 其中 p_i 为 x_i 迭代至当前的最优值, g_i 为所有 x_i 迭代至当前的最优值.

2.2 k-means

聚类问题中, 给定点集 $\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\}$, 确定 k 个聚类中心 $\mu_1, \mu_2, \dots, \mu_k$, 使得在距离 ρ 下

$$J(c, \mu) = \sum_{i=1}^m \rho(x^{(i)}, \mu_{c^{(i)}})$$

达到最小, 其中 $c^{(i)}$ 为 $x^{(i)}$ 的分类号.

k-means 在随机初始化 $\hat{\mu}_1, \hat{\mu}_2, \dots, \hat{\mu}_k$ 后迭代执行

$$\begin{aligned} \forall i, \quad c^{(i)} &\leftarrow \arg \min_j \rho(x^{(i)}, \hat{\mu}_j), && \text{确定每个点的分类号,} \\ \forall j, \quad \hat{\mu}_j &\leftarrow \frac{\sum_{i: c^{(i)}=j} x^{(i)}}{\text{card}\{i \mid c^{(i)} = j\}}, && \text{修改聚类中心,} \end{aligned}$$

直到收敛.

2.3 ICP

ICP (Iterative Closest Point 迭代最近点算法) 用于刚体变换下点云数据的配准. 考虑如下问题: 一组点 $\{y_j\}$ 发生微小错动变成另一组点 $\{x_j\}$, 试问什么样的刚体变换 T 能变回 $\{y_j\}$? 即求刚体变换 $T: x_j \rightarrow y_j$. 如果 $\{x_j\}$ 发生了重采样, 成为 $\{x_i\}$, 那么问题变为求刚体变换 T , 使得

$$J(T) = \sum_i \min_j \rho(Tx_i, y_j)$$

达到最小, 其中 ρ 为距离.

ICP 在初始估计 \hat{T} 下对 $\forall i$ 迭代执行

$$\begin{aligned} c_i &\leftarrow \arg \min_j \rho(\hat{T}x_i, y_j), && \text{确定估计变换下最近像点脚标,} \\ \hat{T} &\leftarrow \arg \min_T \sum_i \rho(Tx_i, y_{c_i}), && \text{重估变换,} \end{aligned}$$

直到收敛. 其中重估变换步骤, 当所求问题为 Euclid 空间 2 范数时, 等价于最小二乘解.

3 应用举例

3.1 信号时差定位

\mathbb{R}^n 空间的 $m+1$ 个点 $\{A_0, A_1, \dots, A_m\}$, 其中 $m > n$. 未知点 P 发生一事件, 匀速扩散. A_0 先检测到, 并以此时刻为基准, A_i ($i = 1, 2, \dots, m$) 延迟 t_i 秒检测到. 如何求取 P ? (此问题改自 2012 年百度算法大赛)

将问题写成优化

$$\arg \min_{P \in \mathbb{R}^n} \sum_{i=1}^m \left(\|P - A_i\| - \|P - A_0\| - vt_i \right)^2.$$

注意到这是凸优化问题, 存在全局最优解, 于是可构造下面的迭代 (不是梯度下降)


$$\hat{P} \leftarrow \hat{P} - \alpha \sum_{i=1}^m \left(\|\hat{P} - A_i\| - \|\hat{P} - A_0\| - vt_i \right) (\hat{P} - A_i),$$

只需要调整步长 α 即可使 \hat{P} 收敛到最优解.

构造迭代的理由很简单: 如果 $\hat{t}_i > t_i$, 那就让 \hat{P} 向 A_i 靠近一点就好了.

3.2 医学影像配准

随病变进程的两次影像需要配准, 增强 MRI、增强 CT 两次扫描图像有配准需求. 医学影像不能直接拿来配准, 一种有效的方法是依照骨密度重抽样, 用抽样点做配准, 配准算法采用 ICP. 下图是我之前做的左侧颞下颌配准, 两次影像结果 (1 和 2) 合并成一个图 (3). 具体细节不在此讨论, 只需注意 ICP 本身并不稳定, 依赖于初始位置关系.



3.3 航迹规划

问题抽象如下: 从 P_0 出发, 依次经过 P_1, P_2, \dots , 到 P_n 的曲线中, 求曲率不大于 ρ 的最短曲线. 这一问题应用于车辆路径规划、飞行器空间轨迹规划.


首先考虑 Dubins 曲线问题. Dubins 曲线是在满足曲率不大于 ρ 和给定起点、终点及起点和终点切线方向的条件下的最短路径, 并且路径任何一点切线方向连续变化. Dubins 曲线问题已被解决, 而本例只要确定了每个点的切线方向, 则航迹曲线就是一组首尾相接的 Dubins 曲线. 问题关键是确定每个点的切线方向角 θ_i .

假设在最短路径下, 考虑路径是一条软绳, 两侧拉动软绳, 在曲率圆限制下, 软绳应处于平衡状态. 由此可知, 对于给定 $\hat{\theta}_i$, 正向过程直接求 Dubins 曲线, 反馈过程通过力矩微调 $\hat{\theta}_i$, 即 $\forall i$, 初始化 $\hat{\theta}_i$ 后迭代执行


$$\begin{aligned} C &\leftarrow \text{DubinsCurve}(\{P_i\}, \{\hat{\theta}_i\}), \\ \hat{\theta}_i &\leftarrow \hat{\theta}_i + \alpha \text{TorqueAdjust}(C), \end{aligned}$$

直到收敛, 其中 α 为调整步距.

在不同初始 $\hat{\theta}_i$ 下, 迭代收敛到不同的曲线, 如下图. 这说明此问题对初值敏感, 易陷入局部最优.



为解决此问题, 考虑用多初值. 但多初值有 PSO 算法可用, 下图的结果是 PSO 算法实现的, 结果相对稳定很多. 本例代码见附件, *Dubins* 曲线自 *MATLAB R2018b* 开始提供.



4 结语

这部分是我对两步迭代的理解. 对于梯度下降而言, 局部梯度信息驱动着迭代进行, 正因为梯度只关心目标值是否下降, 因此非凸优化问题, 可能陷入局部最优解; k -means 和 ICP 可视作坐标交替上升, 其坐标就是迭代中的赋值量, 由内在逻辑矛盾驱动; 而 PSO 是用已知的最优解驱动迭代进行.

两步迭代将优化问题转换为迭代不动点问题. 只需要构造一个法则, 使得每一次迭代都向最优值靠近即可. 这也说明, 同一个优化问题, 改变目标函数, 改变迭代策略, 可以保证最优解不变.

对需要指定初值的问题, 不同初值对应不同最优值, 整个可行域被一组局部最优值划分为若干域, 而初值选取恰当与否, 在于是否能够提升选在全局最优值对应域内的概率.

如果您对本文及附件代码有疑问, 可与我联系,
Email: Qingxin6174@gmail.com,
或者您也可以扫描右侧的微信二维码.

